Foxd3 ChIP-seq: динамика связывания по стадиям

Смирнов Евгений, Б05-326

1. Цель

Обработать ChIP-seq Foxd3 для 75% epiboly и 1-2 ss, сравнить с 5-6 ss (пример преподавателя) и 14 ss (семинар), описать изменения binding landscape.

2. Данные

Nuclear BAM (ChIP и Input) для 75ep, 1-2ss, 14ss; для 5-6ss готовые BigWig, narrowPeak, matrix. Геном GRCz11 (NC_007113.7 = chr2, NC_007117.7 = chr6). Все расчёты на кластере через Slurm.

3. Форматы

Формат	Что хранит	Text/Binary	Использование
FASTA	последовательность генома	Text	референс
GTF	аннотация: гены, транскрипты, экзоны	Text	гены в IGV
BAM	выравнивания ридов (позиция, флаги, MAPQ, пара)	Binary	flagstat, bamCoverage, MACS3, FRiP
BAI	индекс BAM для доступа по координатам	Binary	samtools -L, IGV
BigWig	непрерывный сигнал в bins (CPM, log2 ratio)	Binary	IGV, computeMatrix
BED	интервалы chrom/start/end	Text	summits, гены, bedtools
narrowPeak	BED6+4: peak, signalValue, -log10 p, -log10 q, summit	Text	peaks, FRiP, сравнение
peaks.xls	текстовый отчёт MACS3: параметры + таблица peaks (не Excel)	Text	глубина 5-6ss
TSV	таблица с табуляцией	Text	FRiP, pairwise, Jaccard
matrix.gz	матрица peaks × bins сигнала вокруг summit	Binary (gzip)	plotHeatmap / plotProfile
PDF	графика, документ	Binary	рисунки, отчёт

BAM → BigWig → narrowPeak: отдельные alignments → непрерывный нормированный сигнал по геному → дискретные статистически обогащённые интервалы.

4. Методы

samtools flagstat; bamCoverage --normalizeUsing CPM --binSize 10; bigwigCompare --operation log2 --pseudocount 1; macs3 callpeak -f BAMPE -g 1.36e9 -q 0.01; FRiP = reads в peaks / все reads (samtools view -c -L); computeMatrix reference-point ±2 kb от summit, plotHeatmap, plotProfile; bedtools intersect / jaccard / multiinter.

5-6. QC и peak calling: 75ep и 1-2ss

flagstat: 100% mapped, 100% properly paired, 0 duplicates / secondary / supplementary (BAM уже отфильтрованы).

	75ep	1-2ss
ChIP alignments	23 863 894	12 816 614
Input alignments	39 931 858	33 460 348
Peaks	36	40
FRiP	0.0002	0.0001
Топ-peak	NC_007113.7:33,276,014-33,276,551	NC_007113.7:33,276,062-33,276,596
signalValue	21.70	21.23
-log10(p)	109.26	65.27
-log10(q)	100.05	56.18
q-value	8.9e-101	6.6e-57

Топ-peak на обеих стадиях один и тот же (chr2, ~50 kb от klf17).

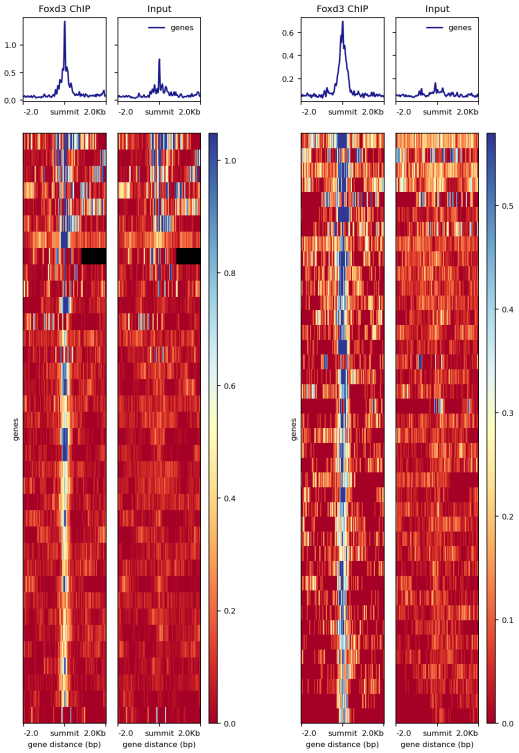


Рис. 1. Heatmap и профиль вокруг summit: 75ep (слева), 1-2ss (справа).

Сигнал в summit слабый (~1.4 и ~0.7 CPM), на 75ep в Input тоже есть пик в центре, то есть часть peaks сидит в регионах с повышенным фоном.

7. Сводная таблица

Stage	ChIP alignments	Input alignments	Peaks	FRiP	max -log10(q)
75ep	23 863 894	39 931 858	36	0.0002	100.05
1-2ss	12 816 614	33 460 348	40	0.0001	56.18
5-6ss	18 853 396	~57 051 062*	839	0.0024	163.70
14ss	41 553 880	27 794 668	170	0.0016	321.45

** 2 × число фрагментов control из peaks.xls (Input BAM для 5-6ss не дан).*

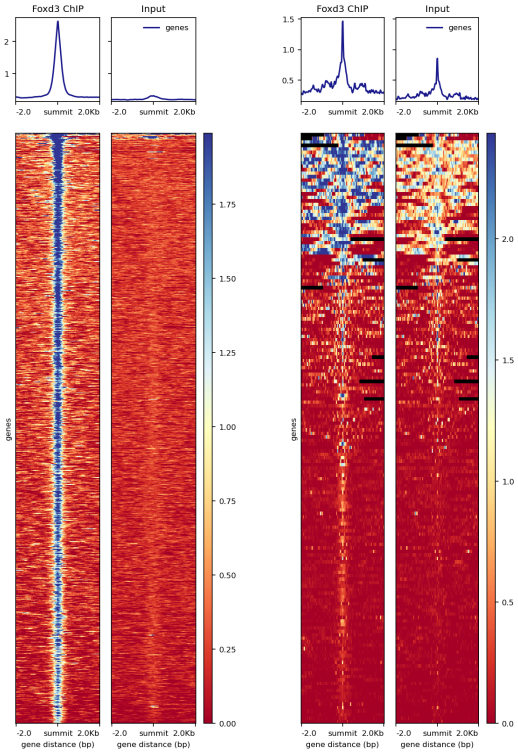


Рис. 2. Heatmap и профиль: 5-6ss (слева), 14ss (справа).

• Больше всего peaks и самый выраженный enrichment на **5-6ss** (839 peaks, максимальный FRiP, чистый профиль при плоском Input).

• Высокий max -log10(q) у 14ss объясняется глубиной (41.5 M), а не силой сигнала: медиана signalValue 3.3, пик в Input, часть топ-peaks на скаффолдах NW_ (вероятные артефакты).

• Разницу нельзя объяснять только биологией: глубина ChIP отличается в 3 раза, FRiP в 17 раз, разная глубина Input, у 1-2ss самая мелкая библиотека. Также влияют качество антитела, доля Foxd3+ клеток в эмбрионе, порог q, повторы и артефакты сборки.

8. Сравнение стадий

A	B	peaks A	peaks B	A ∩ B	A-spec.	B-spec.	Jaccard
75ep	1-2ss	36	40	12	24	28	0.174
75ep	5-6ss	36	839	22	14	817	0.023
75ep	14ss	36	170	18	18	152	0.075
1-2ss	5-6ss	40	839	30	10	809	0.028
1-2ss	14ss	40	170	12	28	158	0.043
5-6ss	14ss	839	170	40	799	130	0.037

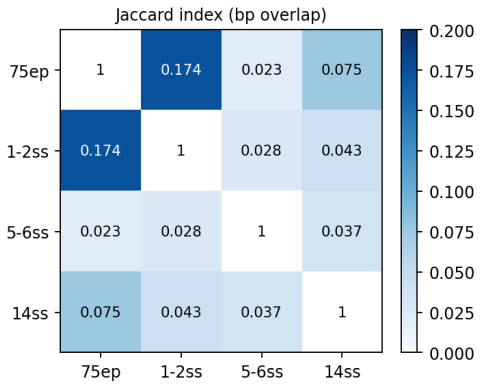


Рис. 3. Матрица Jaccard.

Регионов на 1 стадии: 1057, на 2: 96, на 3: 25, на всех 4: 6.

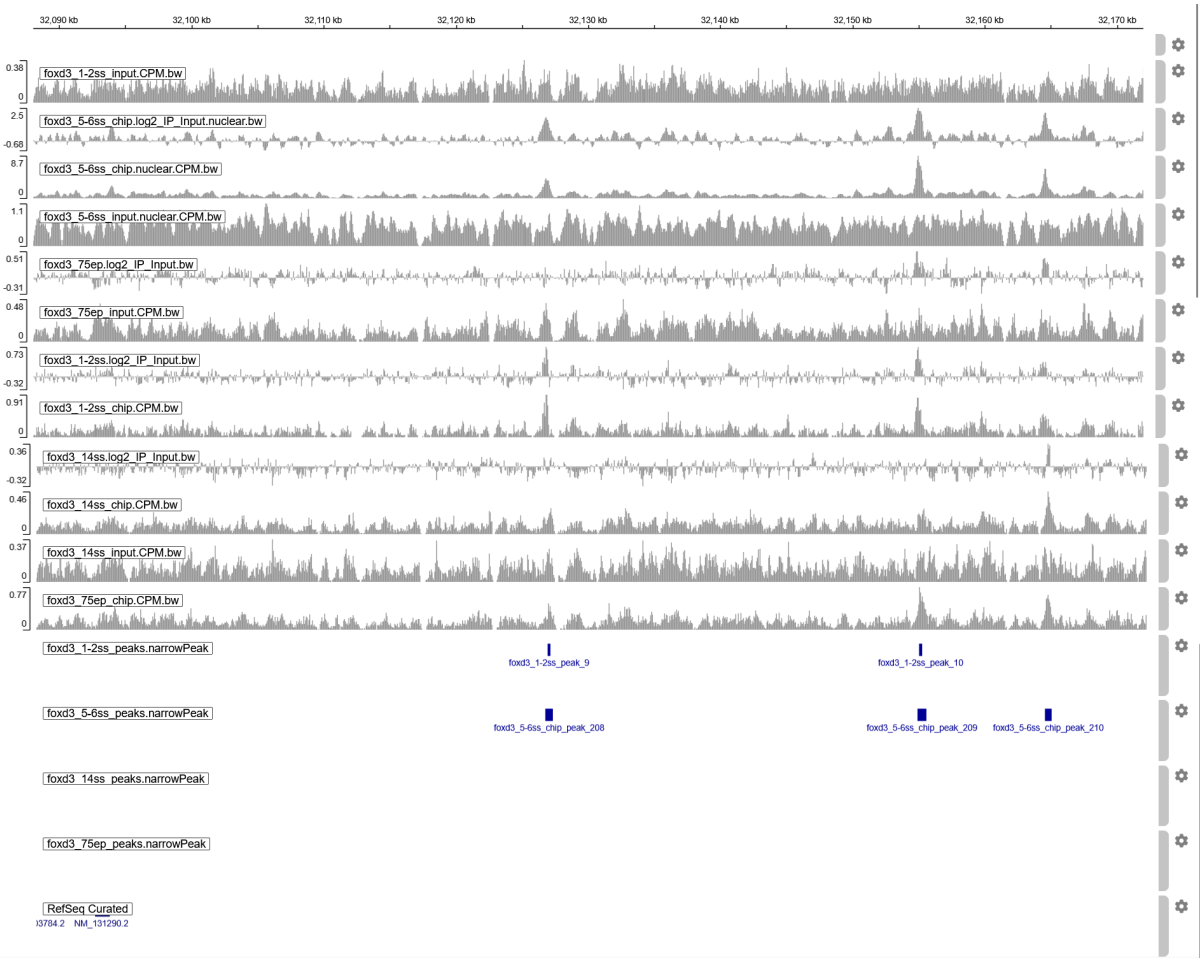
1. Наиболее похожи 75ep и 1-2ss (Jaccard 0.17).

2. Наиболее различаются 75ep и 5-6ss (0.023); для 5-6ss vs 14ss общих только 40 из 839.

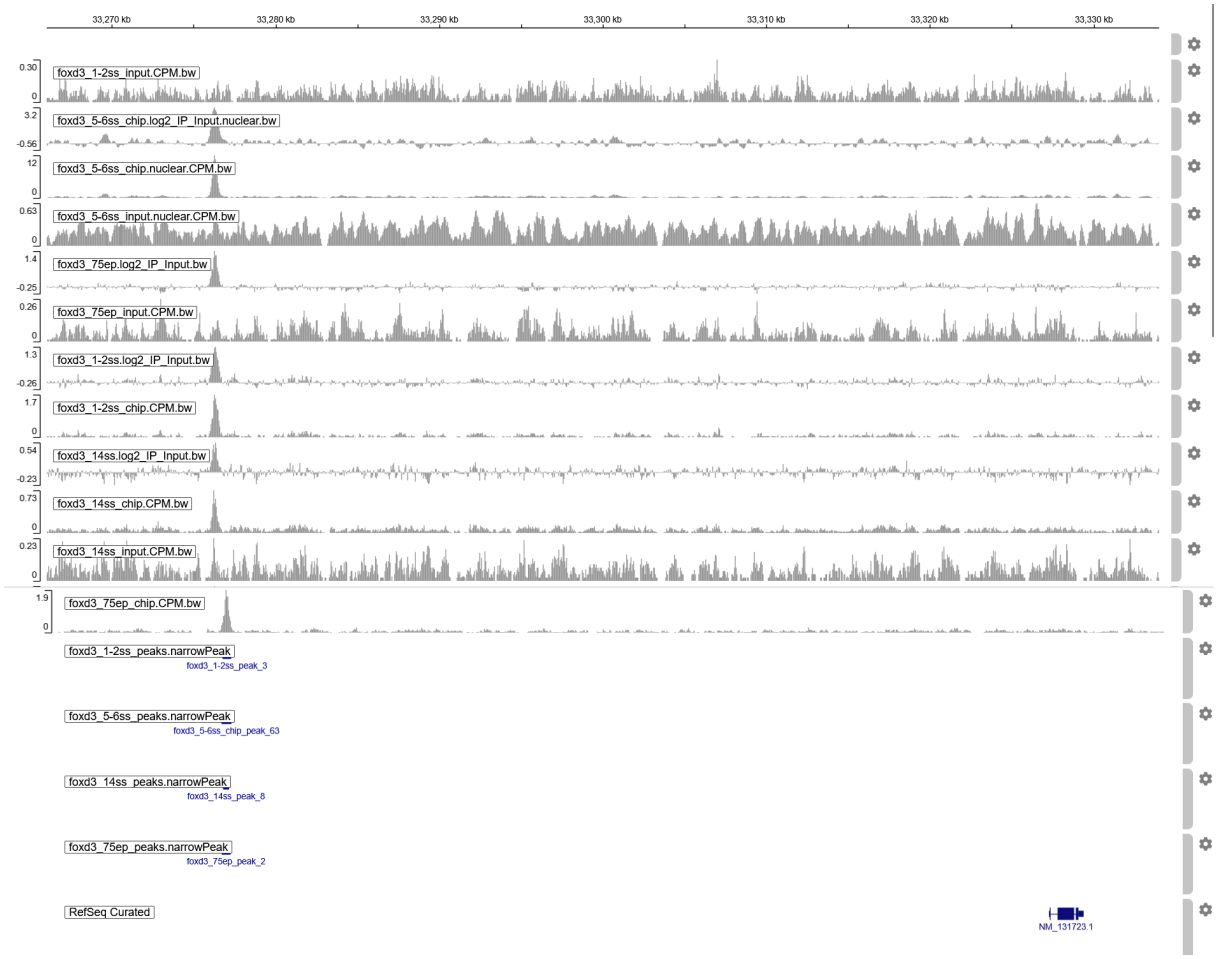
3. Да, перестройка сильная: расширение к 5-6ss и смена набора к 14ss при малом стабильном ядре.

4. Peak это решение по порогу: слабое связывание не проходит q < 0.01 из-за глубины, фона или шума. «Не найдено» не равно «нет связывания».

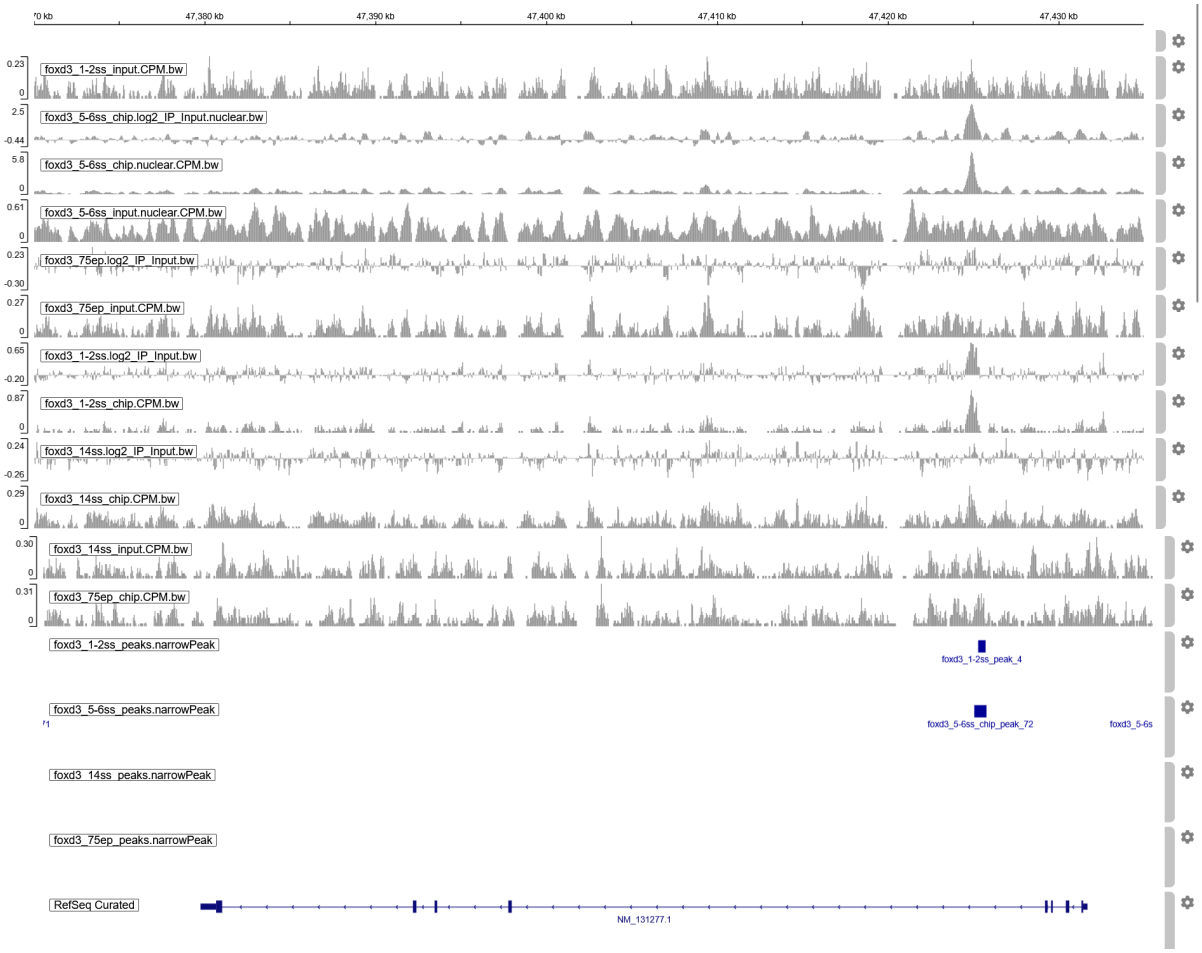
9. IGV



Скриншот 1. chr6 (NC_007117.7):~32,088,000-32,172,000. Слева foxd3 (NM_131290.2). Сильный peak 5-6ss 32,154,676-32,155,349 (ChIP до 8.7 CPM, log2 до 2.5, Input ровный); ещё два peaks рядом, 33-71 kb upstream foxd3.



Скриншот 2. chr2 (NC_007113.7):~33,266,000-33,334,000, рядом klf17 (NM_131723.1). Peak на всех 4 стадиях, но enrichment разный: ChIP CPM 5-6ss 12, 75ep 1.9, 1-2ss 1.7, 14ss 0.73; log2 3.2 / 1.4 / 1.3 / 0.54.



Скриншот 3. chr2 (NC_007113.7):~47,370,000-47,435,000, pax3a (NM_131277.1). Peak 47,424,560-47,425,276 сильный на 5-6ss, слабее на 1-2ss, отсутствует на 75ep и 14ss.

10. Интерпретация

1. Landscape не постоянен: большинство peaks стадиеспецифичны.

2. Максимальный сигнал на 5-6ss.

3. Стабильные участки: 6 регионов на всех стадиях, например сайт у klf17 и элемент ~113 kb upstream foxd3.

4. Появляются к 5-6ss сотни сайтов (pax3a, nfixb, mecom), большинство теряется к 14ss; ранние сайты 75ep (например у gbx1) исчезают.

5. ChIP-seq показывает только связывание: неизвестно, какой ген регулирует элемент, и Foxd3 может быть и активатором, и репрессором.

6. Нужны ATAC-seq (доступность хроматина), H3K27ac ChIP-seq (активные enhancers), RNA-seq (экспрессия генов, лучше при потере Foxd3).

11. Вывод

Связывание Foxd3 динамично: мало сайтов на 75ep и 1-2ss, максимум на 5-6ss, сокращение и смена сайтов на 14ss, небольшое стабильное ядро. Из-за низкого FRiP и разной глубины различия частично технические. Функциональный эффект требует ATAC, H3K27ac и RNA-seq.

12. Команды

```
# на каждую стадию S (sbatch --array=0-2, 8 CPU, 32G)
samtools flagstat -@ 8 foxd3_${S}_chip.nuclear.bam
bamCoverage -b $BAM -o ${S}_chip.CPM.bw --normalizeUsing CPM --binSize 10 -p 8
bigwigCompare -b1 chip.CPM.bw -b2 input.CPM.bw --operation log2 --pseudocount 1 -o log2.bw
macs3 callpeak -t chip.bam -c input.bam -f BAMPE -g 1360000000 -q 0.01 -n foxd3_${S}
FRiP = samtools view -c -L peaks.narrowPeak chip.bam / samtools view -c chip.bam
sort -k9,9gr peaks.narrowPeak | head -1          # топ-peak; q = 10^-col9
computeMatrix reference-point --referencePoint center -R summits.bed \
  -S chip.CPM.bw input.CPM.bw -b 2000 -a 2000 --binSize 20 -o matrix.gz
plotHeatmap -m matrix.gz -out heatmap.pdf; plotProfile -m matrix.gz -out profile.pdf

# сравнение (sbatch --dependency=afterok:<jobid>)
bedtools intersect -a A.bed -b B.bed -u | wc -l   # A ∩ B
bedtools intersect -a A.bed -b B.bed -v | wc -l   # A-specific
bedtools jaccard -a A.bed -b B.bed
bedtools multiinter -i 75ep.bed 1-2ss.bed 5-6ss.bed 14ss.bed
```